

Využitie genetického algoritmu na výber atribútov v oblasti behaviorálnej biometrie

Jozef Varga

Fakulta informatiky a informačných technológií
Slovenská technická univerzita v Bratislave
Ilkovičova 2, 842 16 Bratislava 4

Abstrakt . Výber atribútov je v strojovom učení náročnou kombinatorickou úlohou. Atribúty, ktoré neskôr vstupujú do rôznych modelov v strojovom učení, majú veľký vplyv na následnú presnosť a rýchlosť samotného modelu. Toto je jeden z problémov, ktorý sa vyskytuje pri autorizovaní používateľa pomocou behaviorálnej biometrie. Práve pri zaznamenávaní dát o používateľovi získame veľké množstvo atribútov, ktoré znižujú rýchlosť výpočtu a taktiež degradujú kvalitu klasifikácie.

V tomto článku sme vytvorili genetický algoritmus, ktorý používame práve na výber atribútov. Nami vytvorenú metódu porovnávame s bežnými metódami ako sú Variance Inflation Factor (VIF) a výber atribútov pomocou korelácií (CORR). Zvolené metódy boli porovnané pomocou rôznych klasifikátorov, ako sú napríklad K-Nearest Neighbors (KNN), SVM, Naive Bayes a iné. V práci sme využili verejný dataset [1,11], ktorý obsahuje biometrické dáta o používateľoch. Tieto dáta obsahujú informácie o tom, v akom stave sa nachádza používateľ, teda či leží, sedí, kráča, kráča hore schodami, kráča dole schodami alebo stojí. V tejto práci sa ukázalo, že použitie genetického algoritmu zlepšilo výsledky jednotlivých klasifikátorov a má veľký potenciál, čo sa týka využitia, v tejto problematike.

Keywords: Behaviorálna biometria · Genetický algoritmus · Strojové učenie · Výber atribútov.

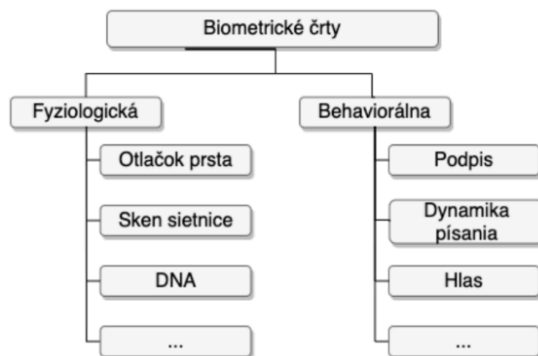
1 Úvod

V dnešnej dobe je využitie smartfónov na vzostupe. Veľké množstvo ľudí tieto zariadenia využíva aj na vyhľadávanie informácií, úpravu dokumentov a rôzne ďalšie funkcionality, ktoré tieto zariadenia podporujú [3]. To, že sú smartfóny veľkou súčasťou technologického sveta potvrdzuje aj štatistika z roku 2018, ktorá hovorí, že až 52,2% zobrazení globálnych webových stránok prebiehalo pomocou mobilných zariadení. Zaujímavé je, že v tomto prípade ide o nárast až 51,5% oproti štatistike z roku 2009 [9]. Mobilné zariadenie prináša veľmi veľa nových možností výskumu, ktoré sú orientované na správanie človeka. Dôvodom je hlavne veľké množstvo informácií, ktoré je možné vďaka senzorom v mobilnom zariadení zaznamenať.

Tieto senzory zaznamenávajú takzvané biometrické črty. Biometria sa zakladá na charakteristických črtách konkrétnej osoby. Tieto biometrické črty sa delia na dva typy, a to na fyziologické a behaviorálne (pozri Obr. 1) [10]. Fyziologická biometria, ako napríklad odtlačok prsta, je veľmi často využívanou overovacou technikou, keďže je jedinečná a stála. Táto biometria má však aj svoje nevýhody. DNA, čo je typickým príkladom tejto biometrie, je dosť invázivne na to, aby sa využívalo napríklad na smartfónoch, keďže jej využitie by vyžadovalo určitú podmienenú činnosť používateľa, napríklad odber krvi. Naopak behaviorálna biometria má výhodu v možnosti práce na pozadí bez akejkoľvek určitej požadovanej činnosti užívateľa. Keďže sa jedná o charakteristiky, ako napríklad rýchlosť písania, nakláňanie smartfónu alebo chôdza, používateľove správanie môže byť overené počas bežných činností [10]. Výhodou behaviorálnych črt je teda fakt, že ak už zariadenie disponuje potrebným hardvérom, v prípade mobilných zariadení napríklad senzormi, je možné vykonávať rôzne operácie, ako napríklad autentifikáciu používateľa alebo identifikovanie stavu, v akom sa používateľ nachádza, bez toho, aby o tom samotný používateľ vedel. Naopak nevýhodou tejto biometrie je, že behaviorálne charakteristiky používateľa sa časom menia, a teda je potrebné častejšie vytvorenie profilu používateľa [8].

Jedným z problémov, ktorý sa objavuje pri prácach s behaviorálnymi atribútmi, je množstvo atribútov, ktoré sa získavajú zo senzorov [5]. Získané atribúty môžu obsahovať irelevantné/zavádzajúce informácie, ktoré môžu mať za následok zníženie kvality klasifikácie modelu [2,4,5,6,14].

Práve výberom atribútov sa budeme v tejto práci bližšie zaoberať. Naša metóda na výber atribútov spočíva vo využití genetického algoritmu, ktorý bude aplikovaný na výber atribútov v datasete, ktorý sa venuje skúmaniu stavu používateľa (leží, chodí, sedí) na základe biometrických atribútov získaných z mobilného zariadenia [1,11].



Obr. 1. Typy biometrických črt [10].

2 Podobné práce

Výber atribútov je veľmi podstatnou časťou pri strojovom učení. Veľmi veľa prác sa zaoberá rôznymi metódami, ktoré by boli nápomocné pri spracovávaní rôznych datasetov. V práci [5] experimentovali nad dvoma databázami, pričom prvá databáza mala 43 atribútov a 231 záznamov. Druhá databáza obsahovala 60 atribútov a 7 555 záznamov. Dáta si rozdelili na testovaciu a trénovaciu množinu v pomere 66:33. Na trénovanie modelu bolo určených 66% dát a 33% dát sa použilo na jeho testovanie. V práci využívajú na klasifikáciu metódu k najbližších susedov (angl. K-Nearest Neighbors, skr. KNN), metódu podporných vektorov (angl. support vector machines, skr. SVM) a naivný bayesovský klasifikátor (angl. Naive Bayes) (pozri Tab. 1). Na konci experimentu autori zhodnotili, že využitie genetického algoritmu na výber atribútov pri rôznych klasifikátoroch malo veľmi priaznivé účinky práve na SVM, a to v zlepšení až o 14,55% v prvom datasete a 11,77% v druhom datasete. Keďže zlepšenie bolo výrazné pri každom zo spomenutých klasifikátorov, autori v práci usúdili, že využitie genetických algoritmov v tejto problematike zvyšuje presnosť klasifikátora.

Tabuľka 1. Presnosť (angl. accuracy, skr. ACC) modelov výberu funkcií v percentách [5].

	Bez výberu funkcií		
Databáza	KNN	SVM	Naive Bayes
Da Silva et al. 2016	72,73 \pm 2,74	73,55 \pm 2,63	55,54 \pm 3,54
Giot et al. 2009	86,72 \pm 0,58	78,28 \pm 0,67	69,33 \pm 0,67
Databáza	Využitie genetického algoritmu na výber funkcií		
Da Silva et al. 2016	87,85 \pm 0,84	88,10 \pm 0,90	81,64 \pm 0,97
Giot et al. 2009	88,86 \pm 0,23	90,05 \pm 0,41	77,44 \pm 0,27

V práci [2] autori využili na výber atribútov tri rôzne algoritmy, a to genetický algoritmus, Waikato pre analýzu znalostí - výber prvkov založený na korelácii (angl. Waikato Environment for Knowledge Analysis - Correlation-based Feature Selection, skr. WEKA-CFS) a Waikato pre analýzu znalostí - výber prvkov založený na hodnotení (angl. Waikato Environment for Knowledge Analysis - ranker, skr. WEKA-ranker). Na vyhodnotenie taktiež použili viacero klasifikátorov a to viac vrstvový perceptron (angl. Multi-Layer Perceptron, skr. MLP), náhodný les (angl. Random Forest, skr. RF), J48, Naive Bayes a regresiu. Najlepšie výsledky boli získané pomocou MLP. Ako najlepší spôsob na výber atribútov sa ukázal práve genetický algoritmus, ktorý má výhodu v širokej možnosti nastavovania.

Práca [14] využila genetický algoritmus na optimalizáciu nielen výberu atribútov, ale aj výberu parametrov pre SVM klasifikátor. Využitie tohto algoritmu, nielen zlepšilo výsledky klasifikácie, ale oproti mriežkovému vyhľadávaniu parametrov (angl. grid search) aj zrýchlilo výpočet o 2,62 sekundy. Presnosť kla-

sifikácie sa zvýšila až o 3,57%. Najnižšie získané hodnoty $83,14 \pm 7,19$ boli s využitím výberu atribútov založenom na genetickom algoritme.

Práca [6] sa zaoberala predovšetkým klasifikátorom C4.5. Autori v nej skúmali ako vplýva genetický algoritmus, ktorého fitness funkcia pozostáva zo stromu, na výber atribútov aj u iných algoritmov. Vo fitness funkcii teda neskúšali využívať len klasifikátor, s ktorým neskôr prebieha klasifikácia. Zistili, že takáto fitness funkcia, taktiež zlepšuje aj iné modely. Ich výsledky ukázali, že ak rovnakú funkciu použili na Naive Bayes, tak jeho klasifikácia sa zlepšila o 4,92%.

Nami vytvorený genetický algoritmus chceme porovnať s existujúcimi algoritmi na výber atribútov, a to faktor inflácie (angl. Variance Inflation Factor, skr. VIF) a výber atribútov na základe korelácií (skr. CORR). Na fitness funkciu chceme využiť len jeden algoritmus, a to KNN, ako bude spomenuté v nasledujúcej kapitole.

3 Využívané algoritmy na výber atribútov

V tejto práci sme sa rozhodli porovnať genetický algoritmus na výber atribútov s algoritmi VIF a výberom atribútov na základe korelácií. Tieto algoritmy sa radia medzi základné algoritmy na výber atribútov [13].

3.1 Variance Inflation Factor

Tento algoritmus odstraňuje atribúty, ktoré majú veľmi silnú kolinearitu. VIF odhaduje do akej miery je rozptyl koeficientu zväčšený kvôli lineárnej závislosti s iným prediktorom. Výpočet VIF pre každý stĺpec (1) sa dá získať vykonaním lineárnej regresie tohto stĺpca so všetkými ostatnými stĺpcami [13].

$$VIF_i = \frac{1}{1 - R_i^2} \quad (1)$$


V uvedenom vzorci R_i^2 predstavuje koeficient regresie medzi i -tou premennou a všetkými ostatnými premennými. VIF sa pri výbere atribútov porovnáva a odstraňujú sa hraničné hodnoty [13].

3.2 Výber atribútov na základe korelácií

Atribúty sú vyberané na základe korelačného koeficientu. Koeficient korelácie je miera lineárnej intenzity korelácie. Najčastejšie je využívaný Pearsonov korelačný koeficient. Tento koeficient nadobúda hodnoty medzi 1 až -1 . 1 vo výsledku predstavuje perfektnú pozitívnu koreláciu (podobnosť). Naopak -1 predstavuje perfektnú negatívnu koreláciu (podobnosť). 0 označuje, že medzi prvkami nie je žiadna korelácia / podobnosť. Cieľom tohto algoritmu je odstránenie takmer totožných stĺpcov [13].

3.3 Genetický algoritmus

Genetické algoritmy sú inšpirované evolúciou. Ich základ sa teda skladá z generácií, ktoré sa vyvíjajú a obsahujú určité množstvo chromozómov, ktoré sa spolu volajú populácia. Tieto chromozómy obsahujú kritické informácie potrebné na vyriešenie problému. Tieto algoritmy sa využívajú najmä na optimalizáciu rôznych problémov. Ich uplatnenie je v praxi veľmi široké [2,12]. Nami vytvorený algoritmus začína inicializáciou populácie genetického algoritmu (pozri Obr. 2).



Obr. 2. Schéma genetického algoritmu na výber atribútov.

Inicializácia populácie genetického algoritmu. Pri inicializácii sa nastavujú prvé funkcie genetického algoritmu (pozri Tab. 2). Nastavenie genetického algoritmu bolo na základe testov a opísaných prác [2]. V algoritme je chromozóm reprezentovaný n génmi. Jeden gén predstavuje 1 alebo 0, ktorá hovorí, či sa vo výslednom vektore atribútov nachádza alebo nie. Počet týchto génov n je počtom atribútov, ktoré sú vo vstupnom vektore, a teda koľko atribútov má daný dataset.

Tabuľka 2. Nastavenie genetického algoritmu.

Parametre GA	hodnota
Fitness funkcia založená na modeli	K-Nearest Neighbors [2]
Reprezentácia génu	Boolean
Maximálny počet generácií	20
Veľkosť populácie	100
Chromozómy vytvorené krížením	30
Chromozómy vytvorené generovaním	30
Najlepšie chromozómy z minulej generácie	20
Percentuálna šanca mutácie a kríženia	60%

Ohodnotenie populácie pomocou fitness funkcie. Populácia, ktorá sa dostane do tohto kroku, musí byť ohodnotená pomocou fitness funkcie. Táto funkcia

musí ohodnotiť jednotlivé chromozómy tak, aby bolo možné ich porovnať a zistiť, ktorý z týchto chromozómov je najúspešnejší. Táto fitness funkcia pozostáva z priemeru desaťnásobnej krížovej validácie, ktorej jadro je vytvorené z KNN algoritmu. Najlepšie hodnotený chromozóm sa uloží ako aktuálny výsledok a algoritmus pokračuje na výber jedincov (chromozómov) do ďalšej generácie.

Výber silných jedincov. Tento spôsob sa nazýva elitárstvo, teda koľko najlepších chromozómov z predchádzajúcej generácie prejde do novej generácie. Výhodou je hlavne to, že silné jedince sa naďalej reprodukovujú a predávajú svoje vlastnosti novovytvoreným chromozómom.

Kríženie jedincov. Pri krížení sa spájajú vlastnosti dvoch jedincov do jedného (pozri Obr. 3). Do kríženia vstupujú dva chromozómy, ktoré majú zrkadlové postavenie v zoradenom liste podľa fitness funkcie. Jeden chromozóm je teda z časti, kde je fitness funkcia najsilnejšia a jeden z časti, kde je fitness funkcia naopak slabšia. Tento spôsob by mal pomôcť algoritmu, aby nezastal na lokálnom maxime. Následne sa prechádza po génoch jednotlivých chromozómov a podľa percentuálnej náhody sa vyberie jeden z génov do budúceho jedinca. Šanca, s akou sa jednotlivé gény volia, ako aj počet takto vytvorených jedincov sa v genetickom algoritme nastavuje pomocou parametrov (pozri Tab. 2).

60% šanca pre 1. rodiča (silnejší rodič)

1. rodič:	1	0	0	1	0	0	1	0	0	1	
	↑ 0,23	↑ 0,41			↑ 0,43	↑ 0,24		↓ 0,75	↓ 0,88	↓ 0,92	↑ 0,57
2. rodič:	1	1	0	1	0	1	1	1	0	0	
dieťa:	1	0	0	1	0	0	1	1	0	1	

Obr. 3. Kríženie chromozómov.

Zvyšné chromozómy sa náhodne vygenerujú ako pri inicializácii, aby počet chromozómov v každej generácii bol rovnaký. Ako posledné prejde algoritmus k mutácii. Tá prejde všetky chromozómy v zadanej populácii a následne aj jednotlivé gény. Nad každým génom sa vygeneruje náhodné číslo, na základe ktorého sa s 60% šancou gén zmení na opačný (pozri Obr. 4).

60% šanca na mutáciu

pôvodný chromozóm:	1	0	0	1	0	0	1	0	0	1
	0,23	0,41	0,66	0,45	0,43	0,24	0,75	0,88	0,92	0,57
			↓				↓	↓	↓	
mutácia:	1	0	1	1	0	0	0	1	1	1

Obr. 4. Mutácia chromozómov.

4 Experimenty

Konfigurácia genetického algoritmu zobrazená v tabuľke 2 bola zvolená na základe pilotných testov nad rôznymi dátami. V experimente využijeme dataset, ktorý obsahuje behaviorálne záznamy z mobilného zariadenia [1,11]. Tento dataset slúži na klasifikovanie stavu používateľa, a teda či používateľ leží, sedí, kráča, kráča hore schodami, kráča dole schodami alebo stojí. Dataset obsahuje informácie o 30 dobrovoľníkoch vo veku 19 až 48 rokov. Každý používateľ vykonával spomenutých 6 aktivít, pri ktorých mal na páse pripevnený smartfón Samsung Galaxy S II. Dataset obsahuje informácie z gyroskopu a akcelerometra. Z nich sa zaznamenávalo 3-osové lineárne zrýchlenie a 3-osové uhlové rýchlosti pri konštantných 50 Hz. V datasete sa nachádza 3609 záznamov. Každý záznam v datasete obsahuje 561 atribútov, ktoré obsahujú [1]:

- trojosové zrýchlenie z akcelerometra a odhadované zrýchlenie tela,
- trojosovú uhlovú rýchlosť z gyroskopu,
- označenie činnosti,
- označenie konkrétneho subjektu.

Nad týmto datasetom sa snažíme overiť a porovnať silu genetického algoritmu oproti štandardným metódam. V experimente boli použité modely adaptívne zvýšenie (angl. Adaptive Boosting, skr. AdaBoost), rozhodovací strom (angl. Decision Tree), extrémne náhodné lesy (angl. Extra Trees), Naive Bayes, K-Nearest Neighbors, lineárna diskriminačná analýza (angl. Linear Discriminant Analysis, skr. LDA), logistická regresia (angl. Logistic Regression), neurónové siete (angl. Artificial neural networks, skr. ANN), Random Forest, SVM Sigmoid, SVM RBF a kvalitatívna analýza údajov (angl. Qualitative Data Analysis, skr. QDA).

4.1 Algoritmus na vyhodnocovanie.

Na vyhodnocovanie sme použili metriku skúmajúcu presnosť (angl. Accuracy, skr. ACC). Presnosť je jednou z najbežnejšie používaných metrík na vyhodnocovanie klasifikácie a je definovaná ako pomer medzi správne klasifikovanými vzorkami k celkovému počtu vzoriek. Vo vzorci (2) P a N označuje počet pozitívnych a negatívnych vzoriek [7].

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

4.2 Implementácia.

Hore spomenuté algoritmy strojového učenia, boli využité vďaka knižniciam sklearn a statsmodels. Genetický algoritmus je vytvorený podľa návrhu, ktorý je spomenutý vyššie. VIF a CORR je implementovaný čiastočne nami a čiastočne pomocou uvedených knižníc. Pri algoritme CORR využívame z knižníc funkciu corr, ktorá nám vracia hodnotu korelácie a pri VIF sa využíva funkcia variance_inflation_factor, ktorá nám vráti výsledok variancie pre jednotlivý stĺpec. Ostatné časti na odstraňovanie atribútov sú vytvorené nami.

5 Vyhodnotenie

Výsledky experimentu sú zobrazené v tabuľke 3 a tabuľke 4. Využitie genetického algoritmu nám v tomto experimente ukázalo, že časovo najnáročnejší na predspracovanie bol algoritmus VIF. Oproti GA bol tento algoritmus až 13-krát pomalší (pozri Tab. 5). Ak sa predpokladá zlepšenie GA zvýšením počtu generácií, vieme povedať, že výsledky GA je ešte možné zlepšiť zvýšením jeho časového zaťaženia.

Tabuľka 3. Výsledky genetického algoritmu. Jadro funkcie bolo KNN.

Model	ACC			Najlepší výsledok
	GA	VIF	CORR	
AdaBoost	0,54	0,55	0,54	VIF
Decision Tree	0,84	0,85	0,84	VIF
Extra Trees	0,77	0,70	0,68	GA
Naive Bayes	0,79	0,87	0,81	VIF
Nearest Neighbors	0,92	0,14	0,14	GA
Linear Discriminant Analysis	0,95	0,95	0,94	GA, VIF
Logistic Regression	0,95	0,96	0,95	VIF
Neural Net	0,94	0,71	0,69	GA
Random Forest	0,73	0,70	0,70	GA
SVM Sigmoid	0,19	0,19	0,19	Všetky
SVM RBF	0,21	0,19	0,19	GA
QDA	0,87	0,91	0,87	VIF

Čo sa týka počtu atribútov, každý z použitých algoritmov znížil počet atribútov o viac ako polovicu, čím sa znížil čas následného tréningu. Najviac atribútov vyfiltroval VIF, a to až o 70 atribútov viac ako GA. Zaujímavosťou je práve GA, ktorý potvrdzuje, že výberom správneho algoritmu do fitness funkcie sa výrazne zlepši výsledná klasifikácia modelu, ktorý je použitý ako základ tejto

funkcie. Získané výsledky taktiež ukazujú, že nie je potrebné, aby sa zhodovalo jadro fitness funkcie s modelom, ktorý je klasifikátorom. Toto je vidieť hlavne pri modeloch ANN a QDA, kde aj pri použití fitness funkcie s jadrom K-Nearest Neighbors sa zvýšila klasifikácia týchto modelov o viac ako 15% oproti klasifikácii nad neupravenými atribútmi. Najväčšie zlepšenie je vidieť na algoritme K-Nearest Neighbors, kde sa klasifikácia zlepšila o 78%. Dôvodom je práve využitie tohoto algoritmu vo fitness funkcii. Výsledky taktiež ukazujú, že ak bol VIF oproti GA lepší, rozdiel bol najviac 1% okrem QDA, kde bol rozdiel 4% a Naive Bayes s rozdielom 8%. Tieto rozdiely môžu byť zanedbateľné v prípade, ak je potrebné znížiť časové zaťaženie na predspracovanie, keďže VIF je 13krát pomalší.

Tabuľka 4. Počet vybratých atribútov. Jadro fitness funkcie bolo KNN.

Algoritmus	GA	VIF	CORR	Bez funkcie výberu
Počet atribútov	260	190	255	562

Tabuľka 5. Čas trvania jednotlivých algoritmov na výber atribútov. Jadro fitness funkcie bolo KNN.

Algoritmus	GA	VIF	CORR
Počet atribútov	5364,672s	71266,493s	2,403s

6 Záver

Ako už bolo uvedené vo vyhodnotení, experiment sa uskutočnil nad existujúcim datasetom, ktorý obsahoval behaviorálne dáta o stavoch používateľov [1,11]. Dataset bol vyhodnocovaný pomocou 11 modelov, a desaťnásobnej krížovej validácie. Podľa výsledkov uvedených v tabuľke 3 a tabuľke 4 je možné pozorovať, že využitie rovnakého klasifikátora ako je použitý vo fitness funkcii, je veľmi účinné a zvyšuje presnosť klasifikácie. Využitie aj iného klasifikátora má za následok zlepšenie klasifikácie, avšak toto zlepšenie nie je až tak výrazné. Úspešné zníženie počtu atribútov má za následok zrýchlenie následnej klasifikácie. Ďalším zistením je, že klasifikáciu je možné zlepšiť využitím genetického algoritmu oproti klasifikácii neupravených dát.

Proces výberu atribútov je jedným z najdôležitejších krokov v predspracovaní údajov. Datasets obsahujúce behaviorálne dáta obsahujú veľmi veľa atribútov, čo môže vyžadovať vysokú výpočtovú silu. V našom experimente je taktiež vidieť, že GA znížilo počet atribútov o viac ako polovicu s tým, že presnosť klasifikátora sa zvýšila. Práve preto môže výber atribútov, ktoré sú podstatné

pre klasifikáciu, zvýšiť presnosť klasifikácie ako je ukázané vyššie. Použitie genetických algoritmov sa zdá byť lepšie aj oproti VIF vďaka nižšej časovej záťaži. Najlepší klasifikátor pre náš dataset bol Logistic Regression a LDA s 95%. Medzi najlepšie tiež patria ANN s 94% a KNN s 92%.

Ďalšie pokračovanie tejto práce by bolo zamerané na zmeny fitness funkcie, pričom cieľom by bolo sledovať presnosť výsledkov ostatných modelov.

Literatúra

1. Anguita, D. et al.: A public domain dataset for human activity recognition using smartphones. ESANN 2013 proceedings, 21st Eur. Symp. Artif. Neural Networks, Comput. Intell. Mach. Learn. April, 437–442 (2013).
2. Babatunde, O. et al.: A Genetic Algorithm-Based Feature Selection. Int. J. Electron. Commun. Comput. Eng. 5, 4, 899–905 (2014).
3. Bomhold, C.R.: Educational use of smart phone technology: A survey of mobile phone application use by undergraduate university students. Program. 47, 4, 424–436 (2013). <https://doi.org/10.1108/PROG-01-2013-0003>.
4. Lu, H. et al.: A hybrid feature selection algorithm for gene expression data classification. Neurocomputing. 256, 2017, 56–62 (2017). <https://doi.org/10.1016/j.neucom.2016.07.080>.
5. Nascimento, L.D.O. et al.: An investigation of genetic algorithm-based feature selection techniques applied to keystroke dynamics biometrics An investigation of genetic algorithm-based feature selection techniques applied to keystroke dynamics biometrics. SBSeg, 2–5 (2019).
6. Smith, M.G., Bull, L.: Genetic programming with a genetic algorithm for feature construction and selection. Genet. Program. Evolvable Mach. 6, 3, 265–281 (2005). <https://doi.org/10.1007/s10710-005-2988-7>.
7. sokolova, M., Japkowicz, N., Szpakowicz, S.: Beyond accuracy, F-score and ROC: a family of discriminant measures for performance evaluation. In: Australasian joint conference on artificial intelligence. Springer, Berlin, Heidelberg, 2006. p. 1015–1021.
8. Syed, Z. et al.: Touch gesture-based authentication on mobile devices: The effects of user posture, device size, configuration, and inter-session variability. J. Syst. Softw. 149, 158–173 (2019). <https://doi.org/10.1016/j.jss.2018.11.017>.
9. statista.com, 2018. Percentage of all global web pages served to mobile phones from 2009 to 2018. <https://www.statista.com/statistics/241462/global-mobile-phone-website-traffic-share/>. Posledny prístup 10 Marca 2020
10. Teh, P.S. et al.: A survey of keystroke dynamics biometrics. Sci. World J. 2013, (2013). <https://doi.org/10.1155/2013/408280>.
11. UC Irvine Machine Learning Repository, <https://archive.ics.uci.edu/ml/datasets/human+activity+recognition+using+smartphones>. Posledny prístup 10 Marca 2020
12. Whitley, D.: A genetic algorithm tutorial. Stat. Comput. 4, 2, 65–85 (1994). <https://doi.org/10.1007/BF00175354>.
13. Xu, J. et al.: Methods for performing dimensionality reduction in hyperspectral image classification. (2018). <https://doi.org/10.1177/0967033518756175>.
14. Zhao, M. et al.: Feature selection and parameter optimization for support vector machines: A new approach based on genetic algorithm with feature chromosomes. Expert Syst. Appl. 38, 5, 5197–5204 (2011). <https://doi.org/10.1016/j.eswa.2010.10.041>.